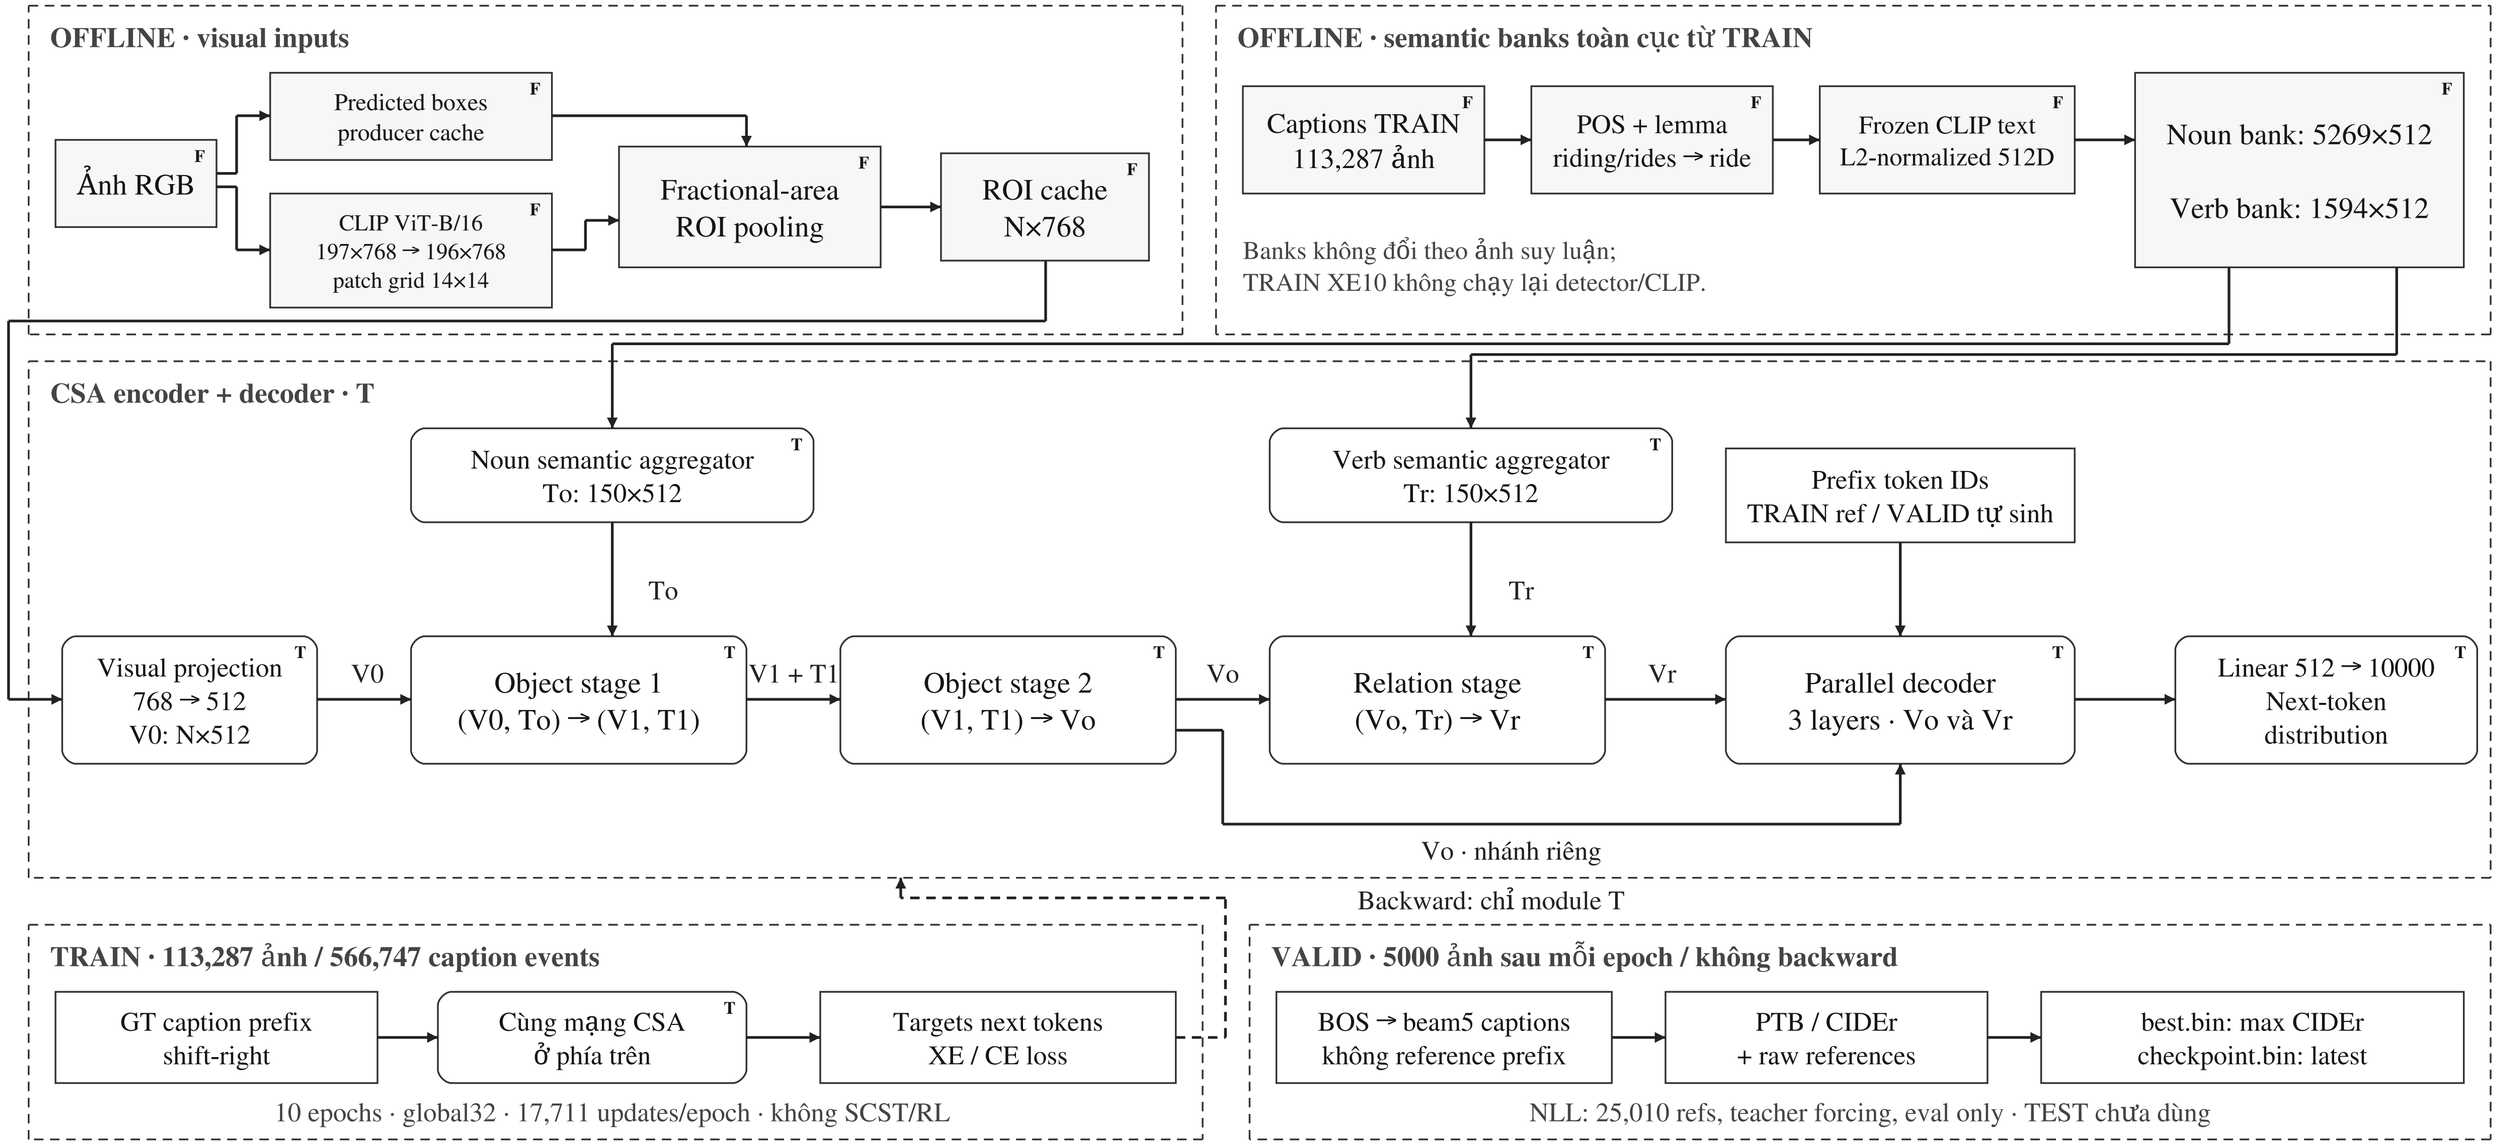
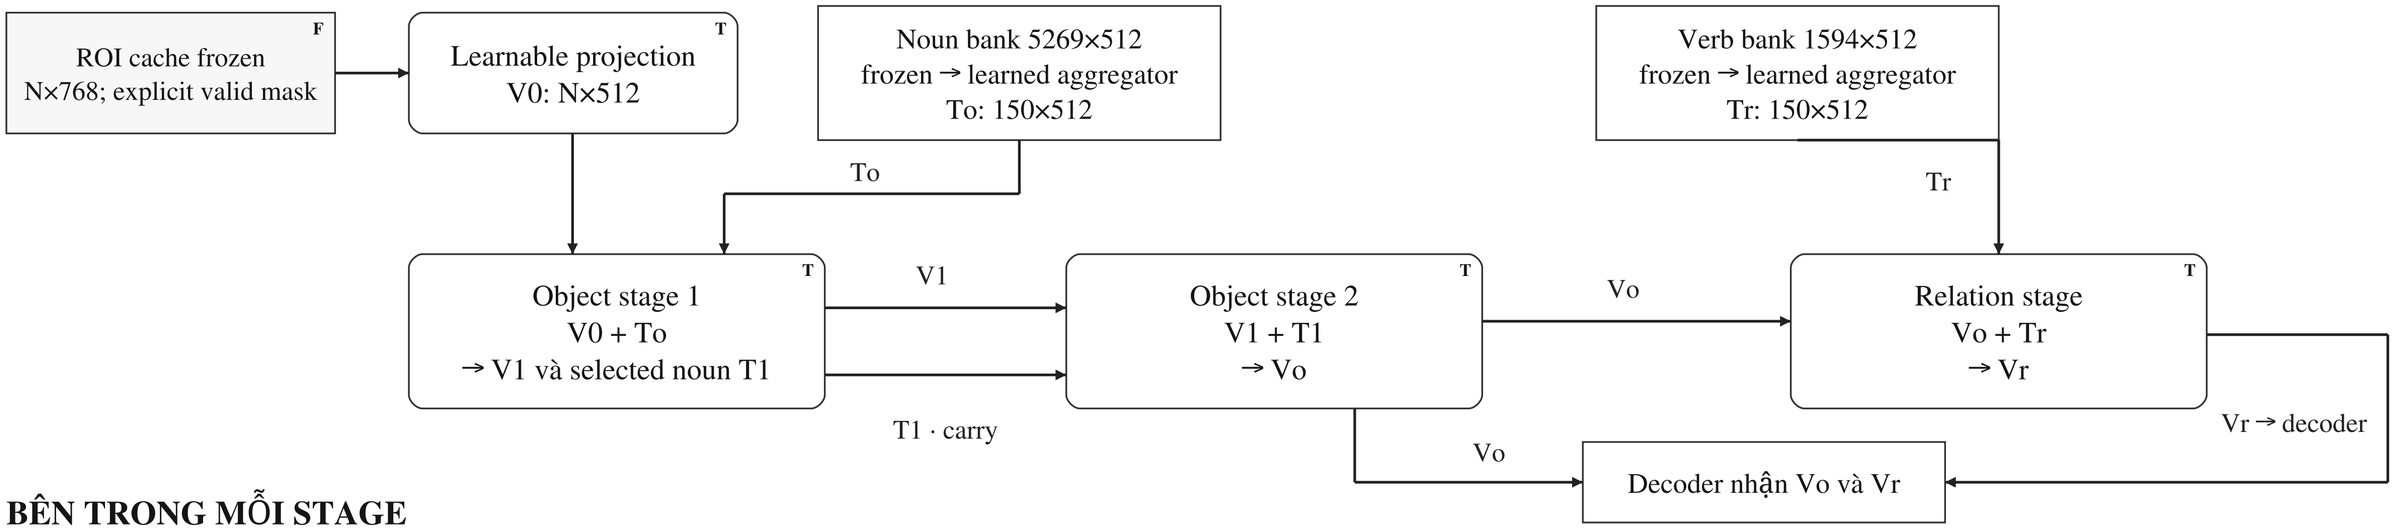
CSA adaptation — cached CLIP ROI + semantic banks

Pipeline hiện tại • tự triển khai theo CSA, thay feature/text encoder • sơ đồ kiến trúc và run XE10, chưa phải kết quả huấn luyện

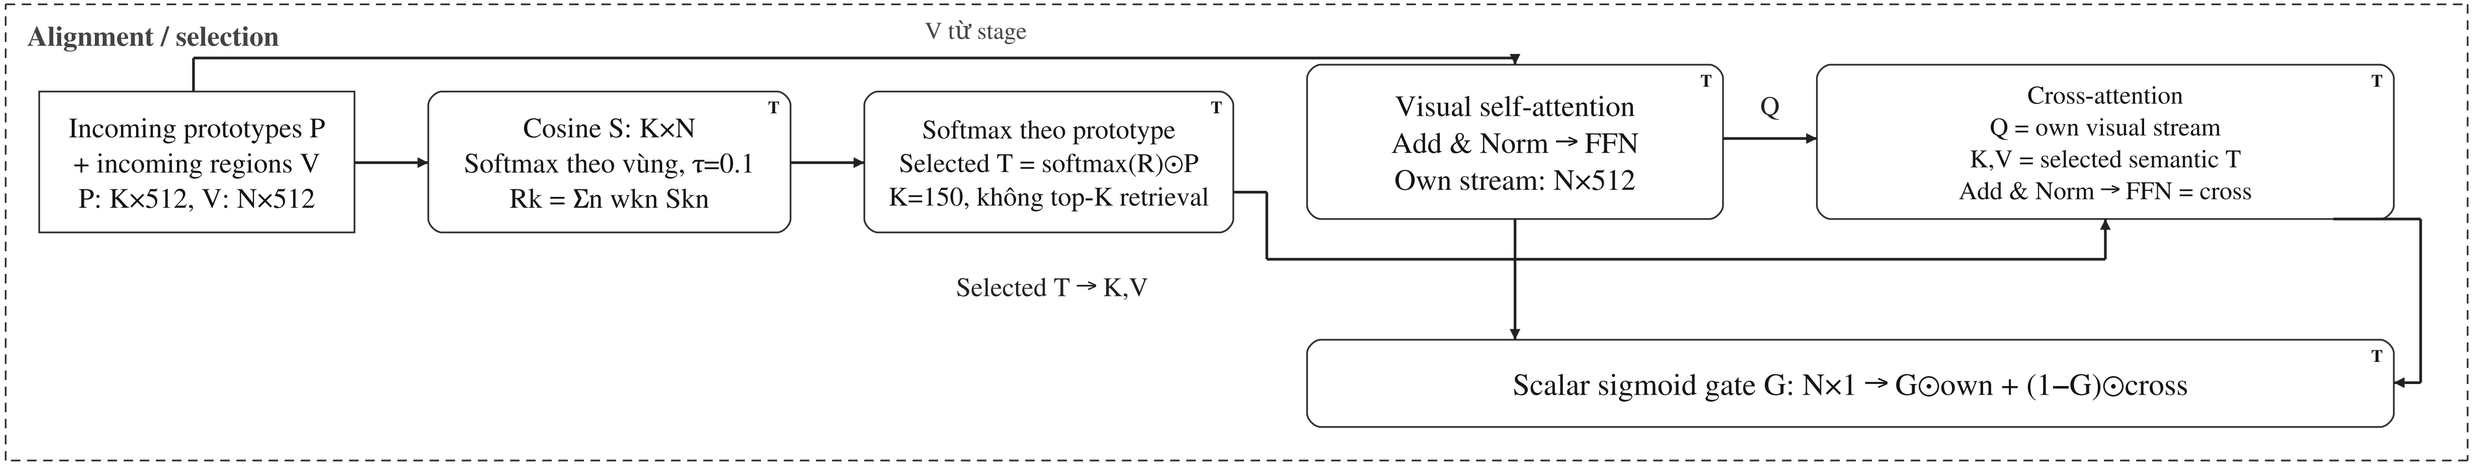


Encoder CSA — hai stage object, một stage relation

Đối chiếu CSACaptioner.encode, Alignment.forward và Fusion.forward • To/T1/Tr là semantic prototypes, không phải UPT triplets



BÊN TRONG MỖI STAGE



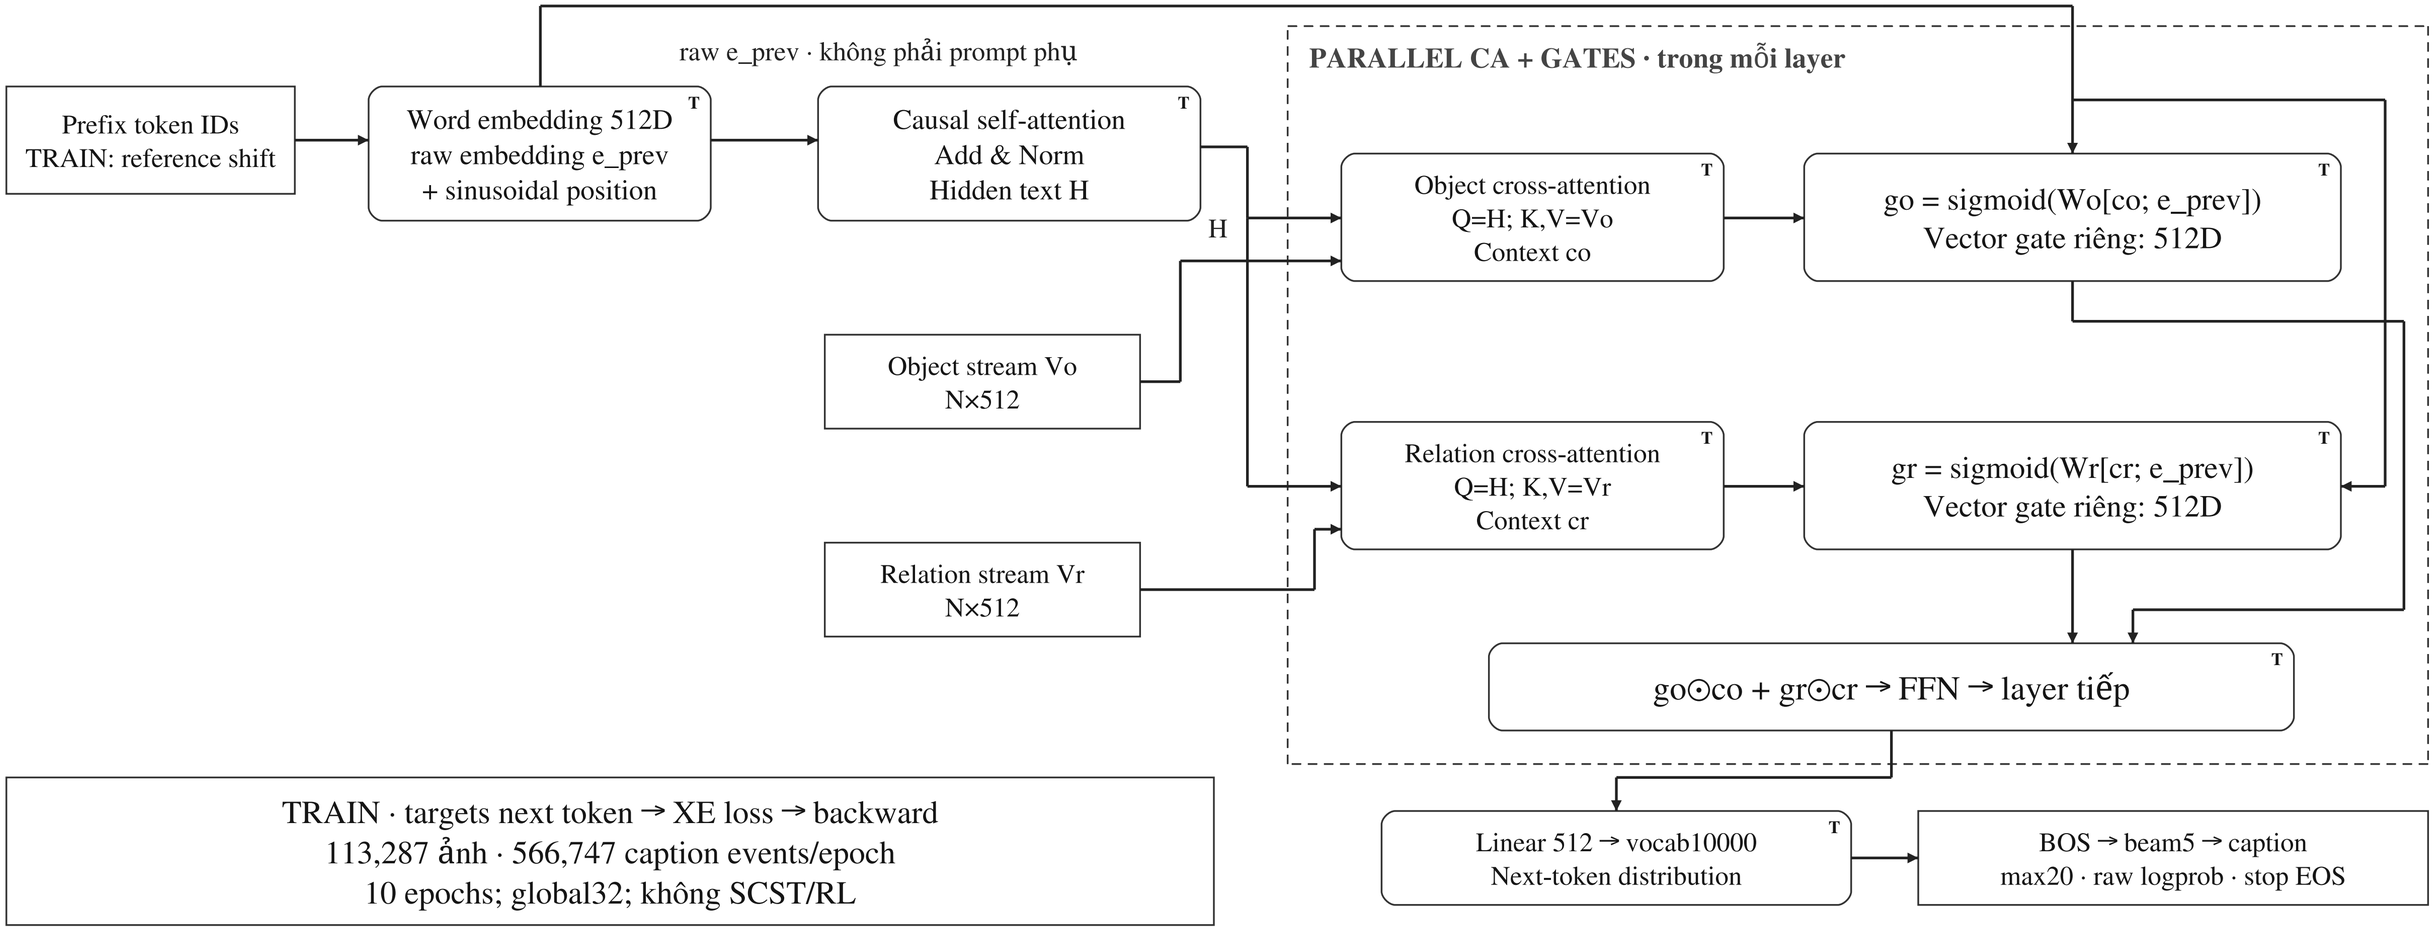
N thay đổi theo ảnh, max87 trong cache full; empty detections → 1 full-frame fallback.
ROI dùng contextual CLIP patches; selection/attention chưa chứng minh mỗi từ caption gắn chính xác một box.

F · frozen / cache | T · trainable | TRAIN only

Khung OFFLINE: chuẩn bị trước • Mũi tên: luồng dữ liệu • Nét đứt: gradient TRAIN

Parallel adaptive decoder và TRAIN / VALID

Vo và Vr được đọc bằng hai cross-attention riêng • Cùng Q là hidden text sau causal self-attention



TRAIN · targets next token → XE loss → backward
113,287 ảnh · 566,747 caption events/epoch
10 epochs; global32; không SCST/RL

VALID · eval, không nhận reference prefix khi sinh
5000 ảnh → beam5 captions + raw refs → PTB / CIDEr
Teacher-forced NLL trên25,010 refs là nhánh đo riêng

Checkpoint selection · không có gradient VALID
best.bin: CIDEr lớn nhất; hòa chọn epoch sớm
checkpoint.bin: latest để resume · TEST chưa dùng

F · frozen / cache | T · trainable | TRAIN only

Khung OFFLINE: chuẩn bị trước • Mũi tên: luồng dữ liệu • Nét đứt: gradient TRAIN