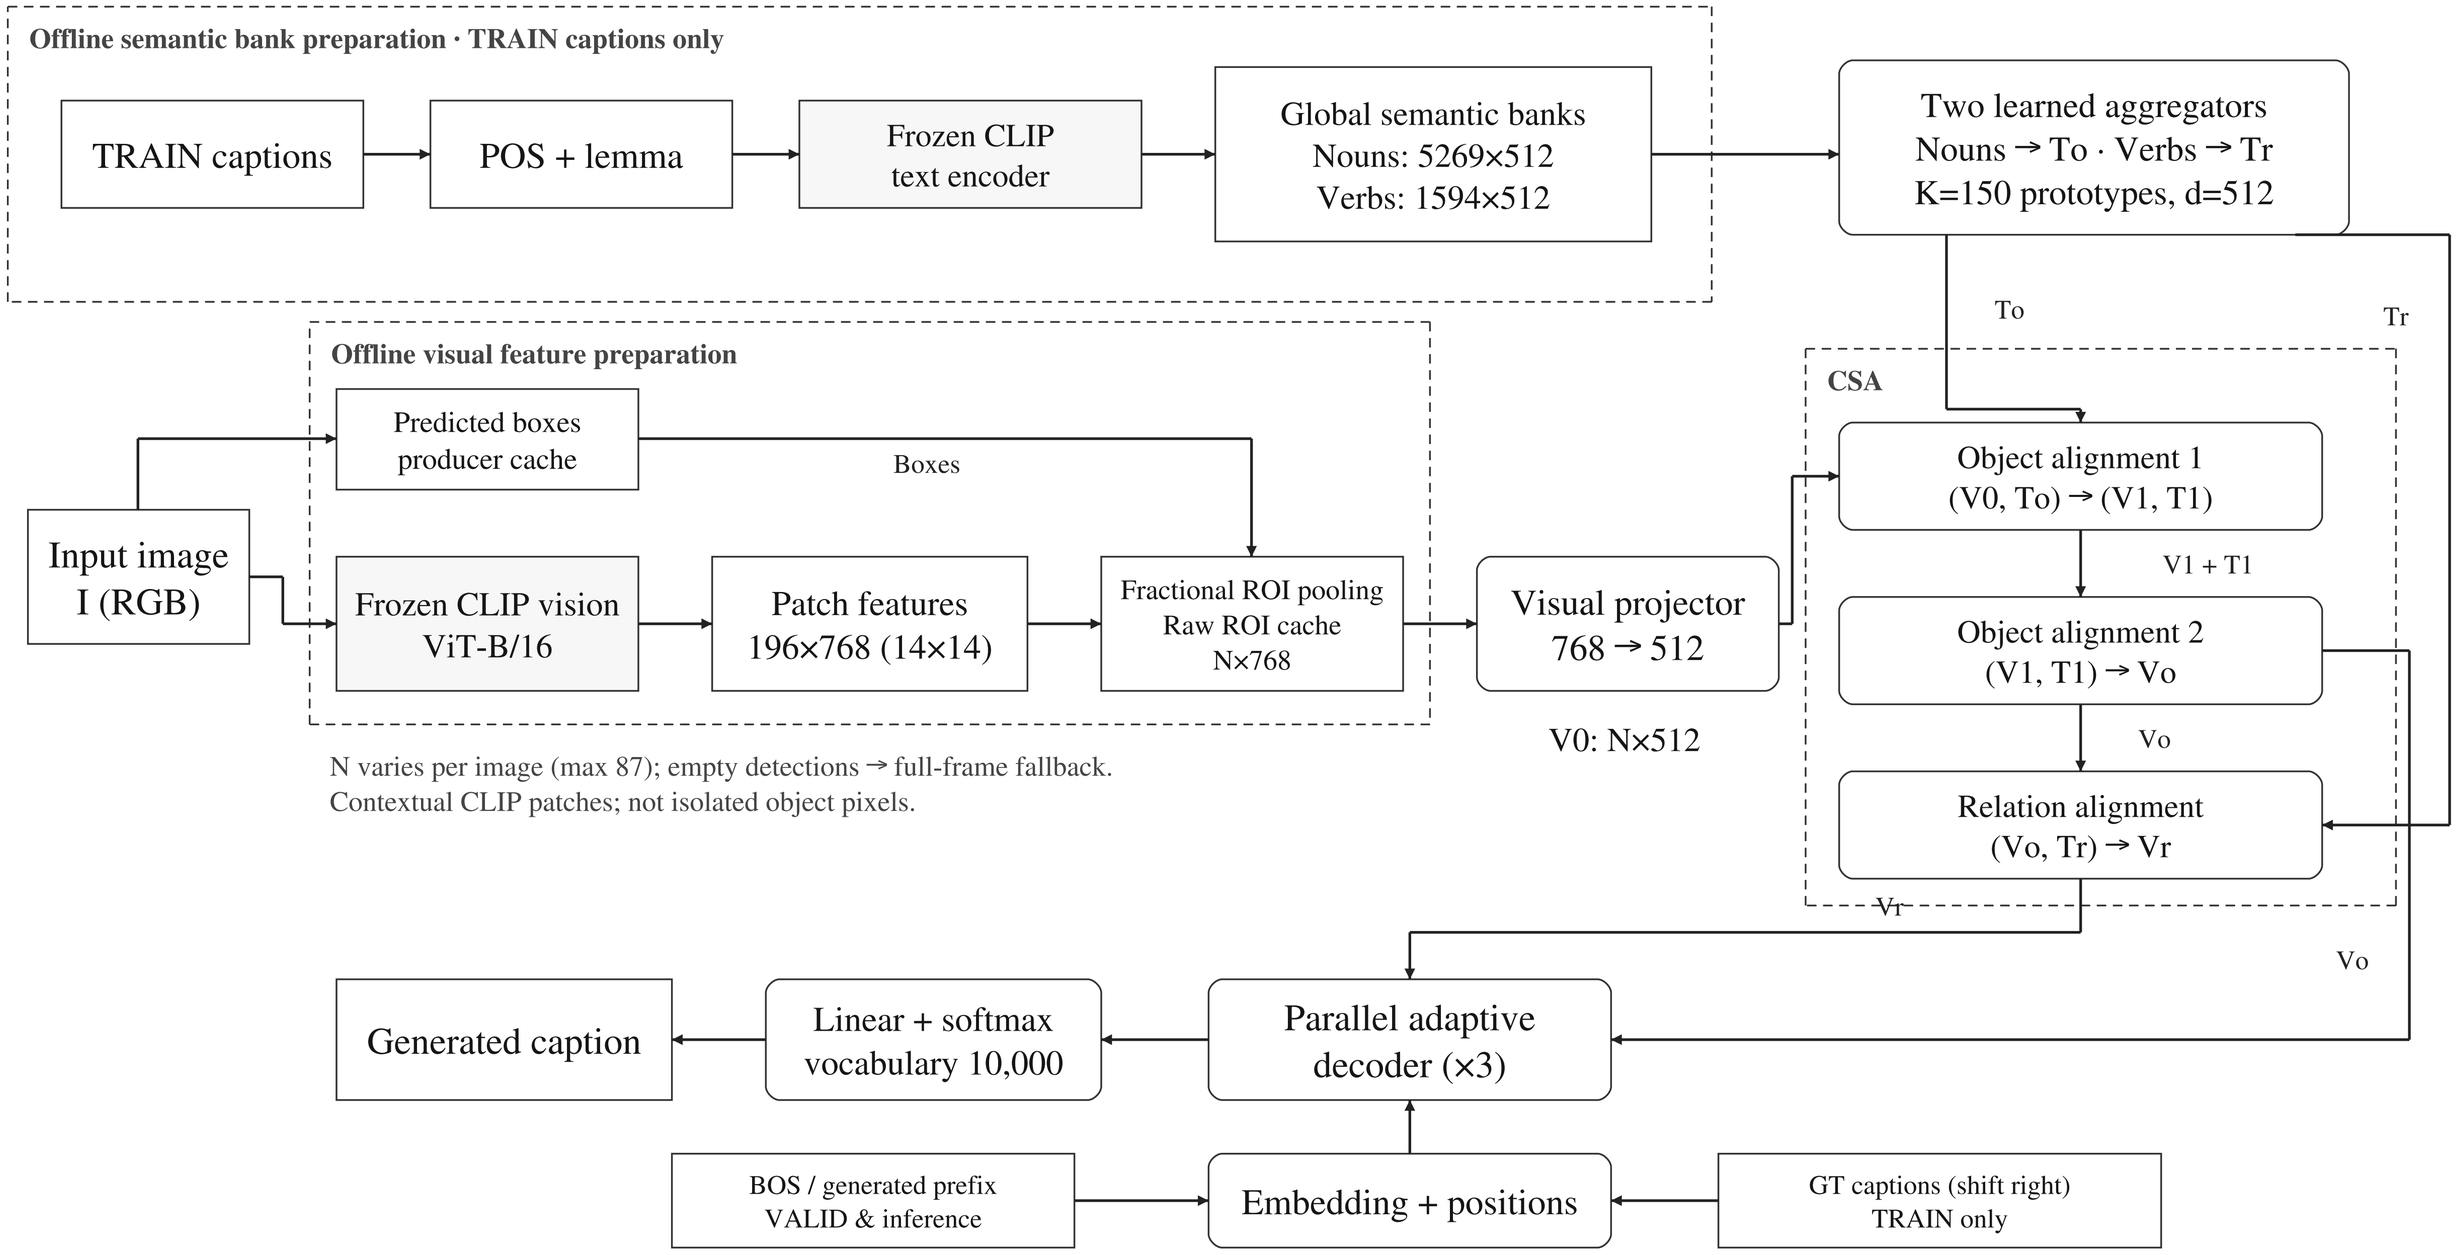
CSA adaptation

Cached CLIP ROI + semantic banks

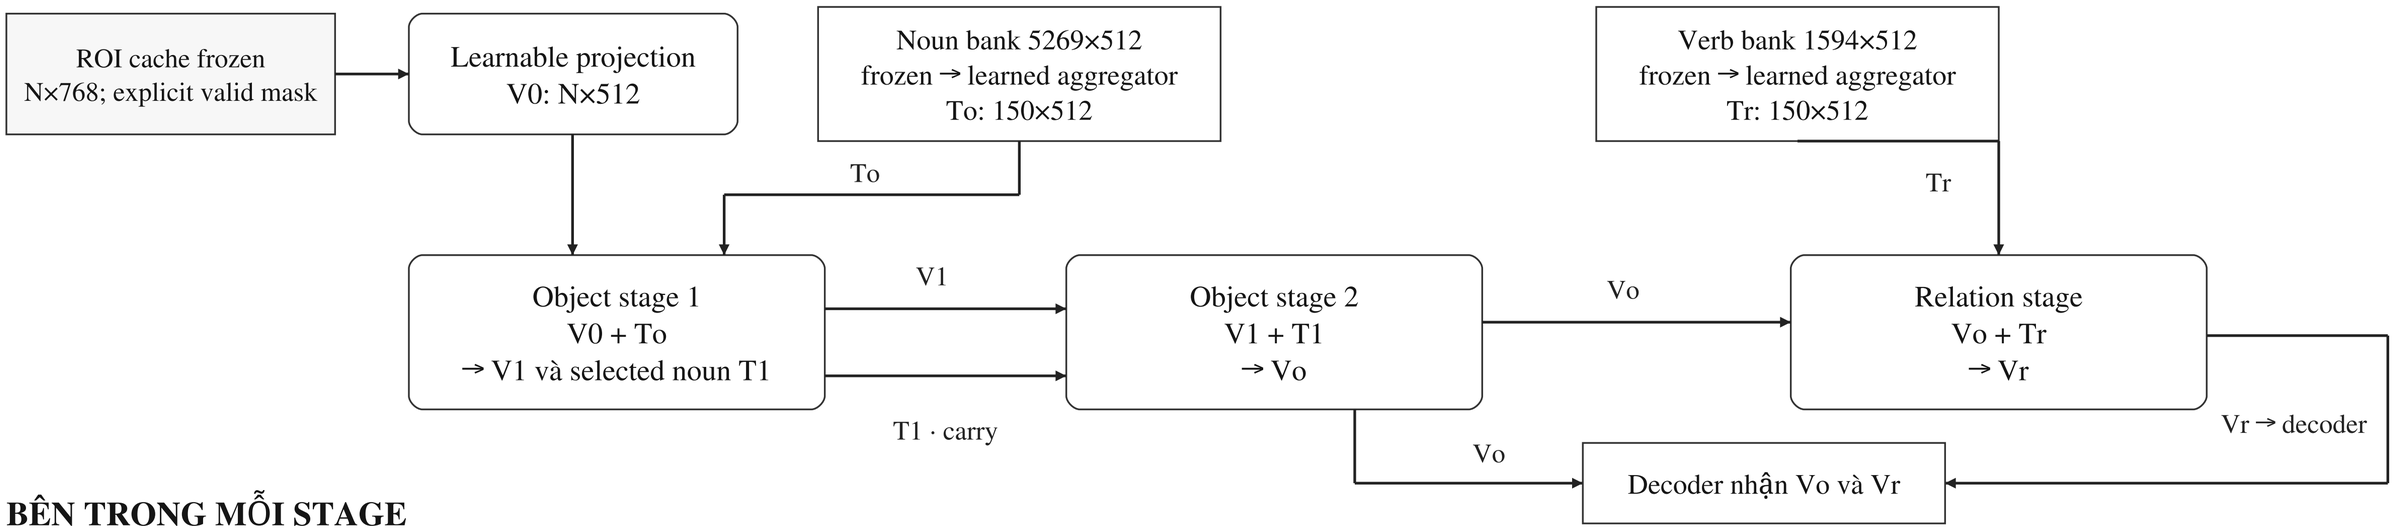


N varies per image (max 87); empty detections → full-frame fallback.
Contextual CLIP patches; not isolated object pixels.

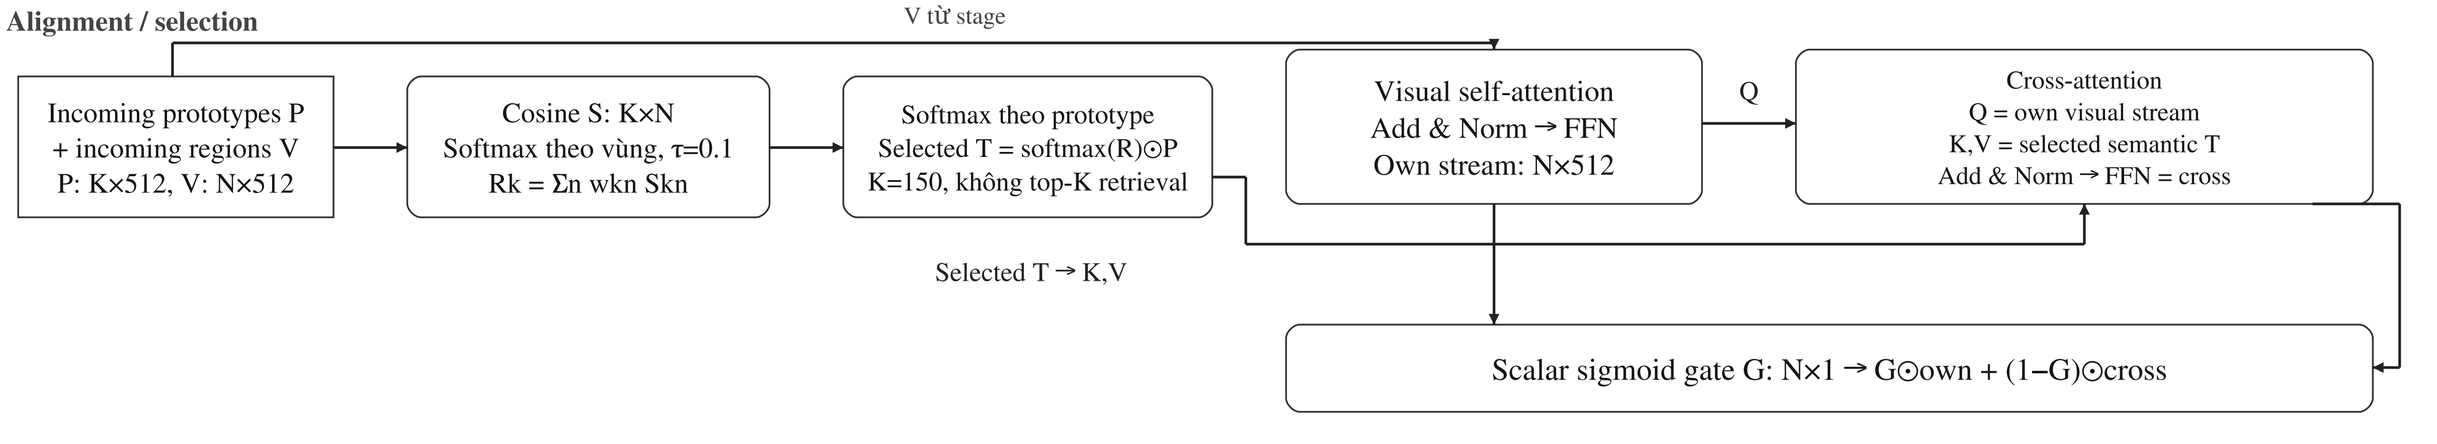
TRAIN: XE loss on next tokens. VALID: beam 5 → CIDEr → best checkpoint; no backward.
Frozen encoders and caches are prepared offline; learned aggregators, projector, CSA and decoder train together.

Encoder CSA — hai stage object, một stage relation

Object → object → relation · Chi tiết selection và visual–semantic fusion



BÊN TRONG MỖI STAGE



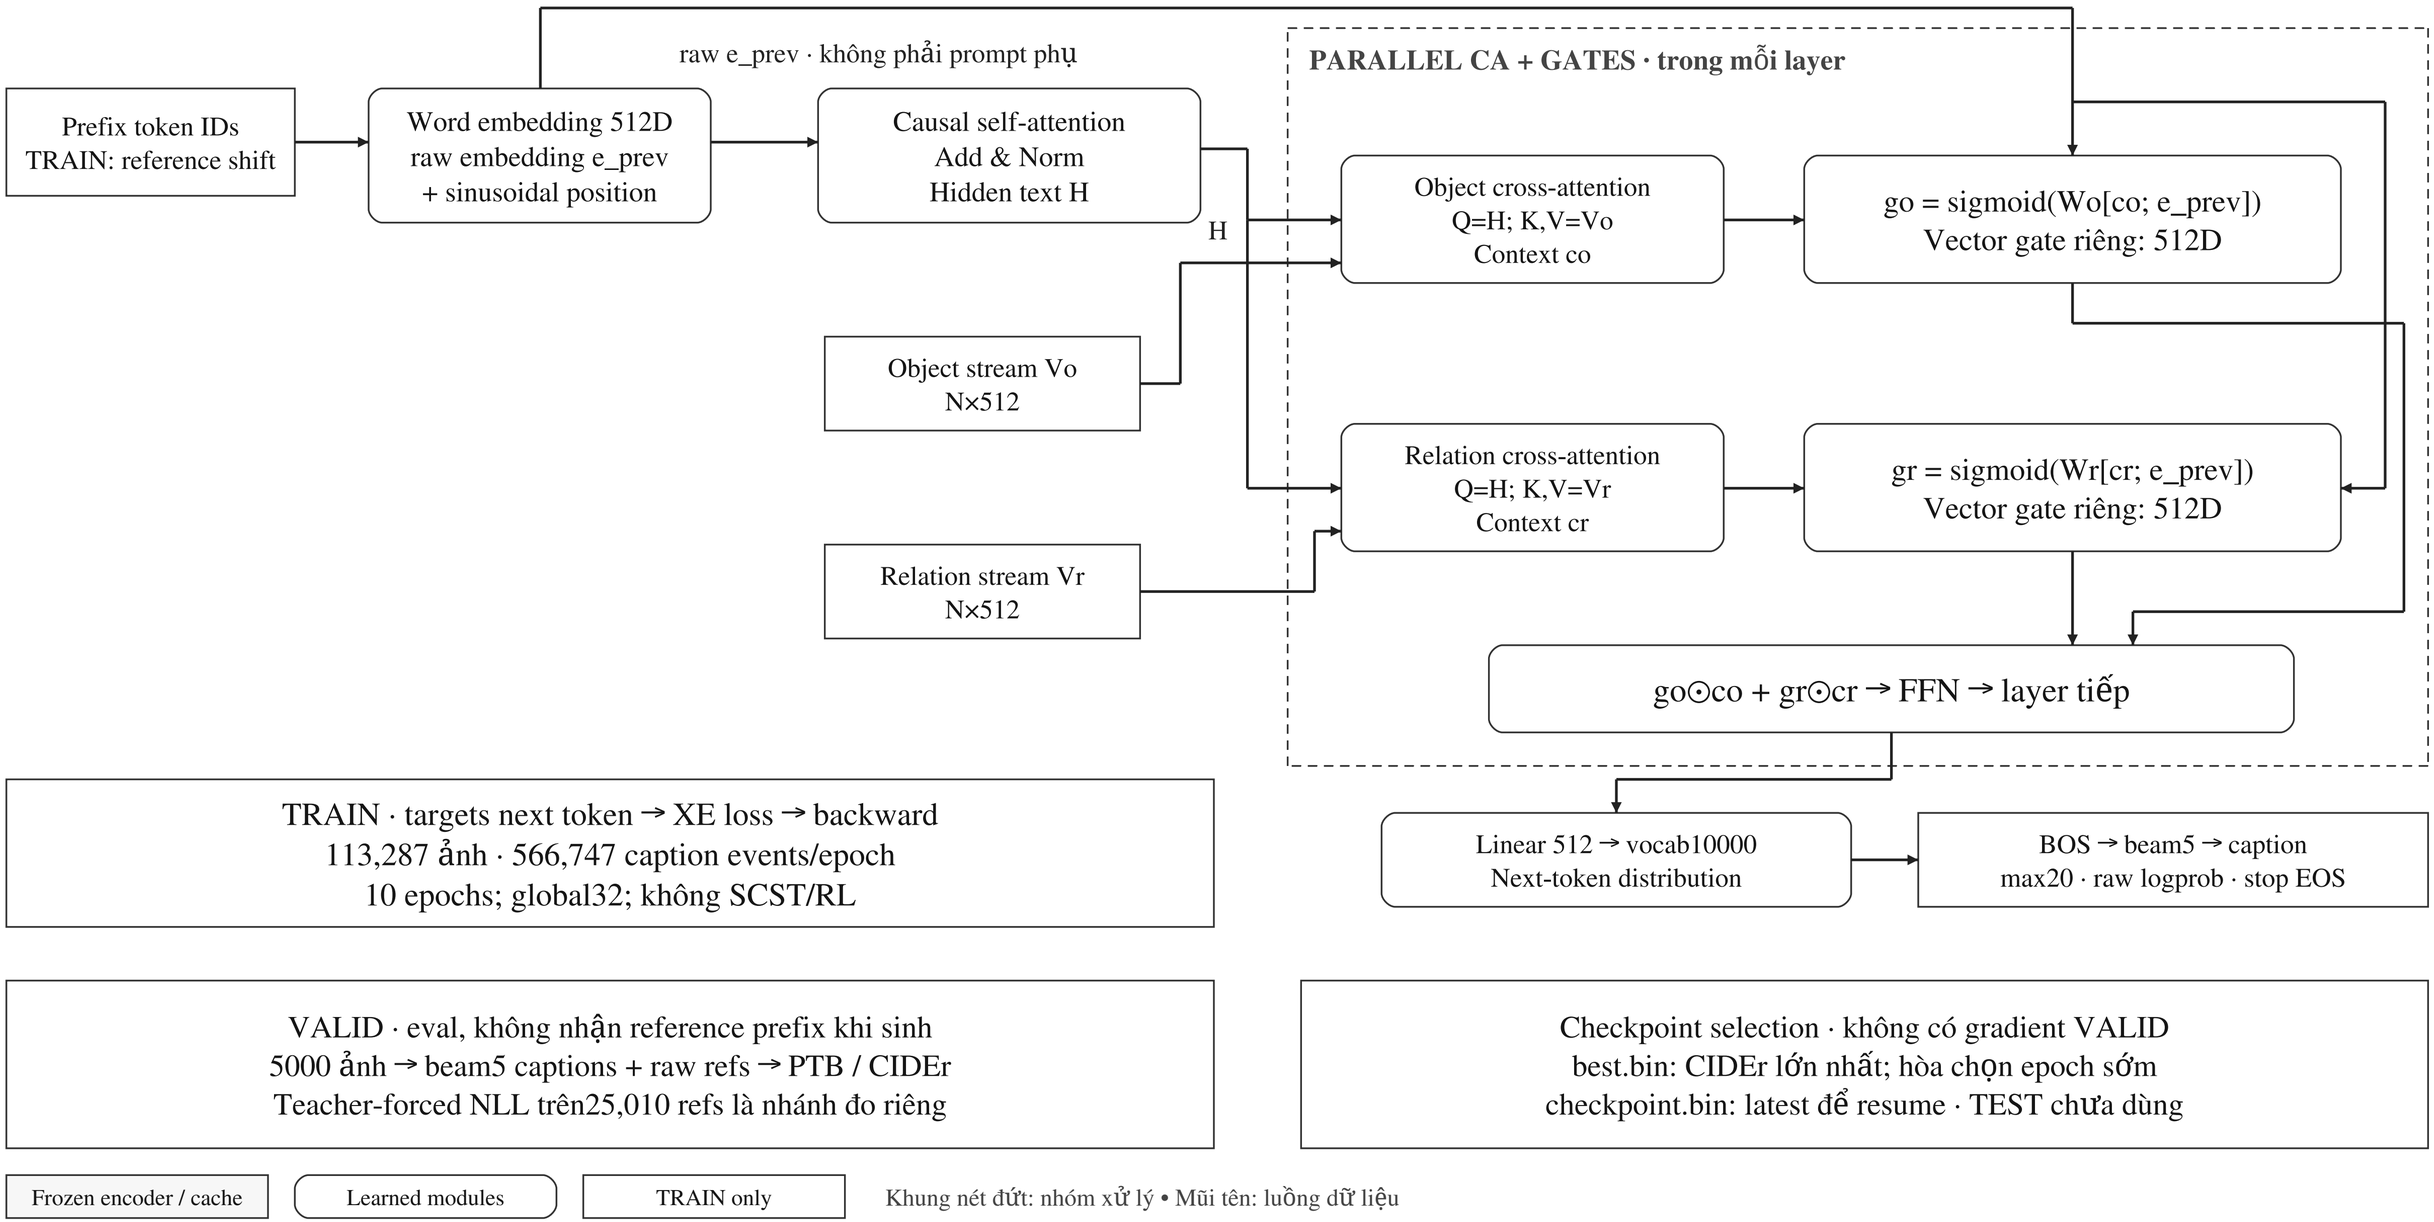
N thay đổi theo ảnh, max 87 trong cache full; empty detections → 1 full-frame fallback.
ROI dùng contextual CLIP patches; selection/attention chưa chứng minh mỗi từ caption gắn chính xác một box.

Frozen encoder / cache | Learned modules | TRAIN only

Khung nét đứt: nhóm xử lý • Mũi tên: luồng dữ liệu

Parallel adaptive decoder và TRAIN / VALID

Vo và Vr được đọc bằng hai cross-attention riêng • Cùng Q là hidden text sau causal self-attention



Khung nét đứt: nhóm xử lý • Mũi tên: luồng dữ liệu